TECHNICAL REPORT · 技术报告

aanm-torch:面向构象动力学的可微弹性网络工具包

ProDy AANM 管线的 PyTorch 重写:数值保真 · 稀疏扩展 · 五个经典工具的可微化

匿名 · Anonymous

aanm-torch: 面向构象动力学的可微弹性网络工具包

技术报告 (v1.2)

2026 年 11 月　开源代码仓库:aanm-torch

摘要　aanm-torch 是 ProDy 生态中自适应各向异性网络模型 (AANM) 形变工具链的 PyTorch 重写, 目标有三: 数值不降级的忠实移植、把可计算体系规模从约 2500 个残基推进到两万个残基、以及全程可微以衔接深度学习工作流。本文报告其实现选择、与参考实现 ProDy 2.4.1 的逐位数值对照 (Hessian 差异 2.5×10^{-14}、逐步 RMSD 差异 6.3×10^{-13})、稀疏优先求解器的实测扩展性 (两万残基单步约 2 分钟), 以及五个经典工具 (SAXS Debye 散射、MinActionPath 最小作用量路径、ANMPathway 式双向路径、ClustENM 系综采样、NMFF 式 cryo-EM 柔性拟合) 的可微重写及其取舍与验证。另附一项试点研究: 将 ANM 软模式投影作为引导势注入 BioEmu 扩散采样, 在腺苷酸激酶上实现约 3 Å 的系综定向牵引, 并给出其当前质量局限的诚实评估。全部结论由仓库内 59 个单元测试与基准脚本支撑。

1　引言与动机

弹性网络模型 (ANM/GNM)[1] 把蛋白主链简化为距离截断的弹簧网络, 其 Hessian 矩阵的低频特征向量即集体运动模式。ProDy[2, 3] 是该领域事实上的参考实现, 其 `calcAdaptiveANM`[4] 在两个构象态之间沿软模式迭代步进, 是构象转换路径生成的常用引擎。本项目的起点是一套基于 ProDy 的分子机器动画管线, 在实践中暴露三个工程瓶颈:

1. **规模上限**。稠密特征分解为 $O((3N)^3)$ 时间、$O((3N)^2)$ 内存, 2500 个残基已在分钟级, 更大的组装体不可行;
2. **不可微、不可批**。逐条转换串行求解, 无法利用 GPU 批量对角化, 也无法把弹性势嵌入梯度学习;
3. **静默缺陷**。主链重建在特定输入下写出空帧、clash 计数系统性漏检、邻居选取跨链借用原子等 (第 4 节)。

aanm-torch 以纯 PyTorch 重写整条管线 (解析除外), 所有张量运算可运行于 CUDA/MPS/CPU, 并保持与参考实现的数值一致性。定位是**技术报告**: 方法学本身属于既有工作, 本文的贡献在于忠实移植的验证方法、规模化的工程路径、以及可微化带来的新用法。

2 核心: 忠实移植与数值保真

2.1 ANM 与自适应步进

N 个节点 (氨基酸取 Cα、核苷酸取 P) 在截断距离 r_c 内以弹簧连接, $3N \times 3N$ Hessian 的块形式为

$$\mathbf{H}_{ij} = -\frac{\gamma}{r_{ij}^2}\,\hat{\mathbf{r}}_{ij}\hat{\mathbf{r}}_{ij}^{\top}, \qquad \mathbf{H}_{ii} = -\sum_{j\neq i}\mathbf{H}_{ij}, \tag{1}$$

其中 $\hat{\mathbf{r}}_{ij}$ 为单位方向向量、γ 为弹簧常数。自适应 AANM[4] 每步在当前结构处建网、取最软的若干非刚体模式, 把指向目标的形变向量 $\mathbf{d}$ 投影到模式子空间得到组合步进方向 $\mathbf{v}$, 并以

$$s = f\,\frac{\mathbf{v}^{\top}\mathbf{d}}{\mathbf{v}^{\top}\mathbf{v}}, \qquad \mathbf{x} \leftarrow \mathbf{x} + s\,\mathbf{v} \tag{2}$$

更新坐标, 配以动态 Fmin 选模、模式数倍增与三条收敛判据 (RMSD 停滞、达标、断链)。aanm-torch 将整个步进核 (`_step_core`) 统一供单向、交替 (alternating) 与多转换批量三种驱动共享, 保证不同执行路径应用完全一致的更新。

2.2 与 ProDy 2.4.1 的数值对照

表 1 汇总 SERCA(E1.2Ca→E1.ATP,994 个公共 Cα) 上的对照, 参考值由设计者 venv 内的 ProDy 2.4.1 子进程产生, 浮点环境一致 (float64/CPU)。该对照作为单元测试长期保留于仓库。

表 1: 与 ProDy 2.4.1 的数值对照 (SERCA,994 Cα)

量	最大差异
ANM Hessian(逐元素)	2.5×10^{-14}
逐步 RMSD(10 步)	6.3×10^{-13}
路径帧坐标	4.4×10^{-12} Å
完整轨迹 PDB(v1.0 语义,16 帧)	1e-3 Å 输出精度下逐位一致
合成体系 (含停滞用例)	1.8×10^{-15}(ProDy 同步停滞)

值得记录的一点: 合成测试中发现单向 AANM 在螺旋径向扩张类形变上停滞, 与 ProDy 的逐步 RMSD 完全一致至 10^{-15}——停滞是算法固有行为 (最软模式为弯曲而非扩张), 交替模式才是此类体系的正确工具。这促使我们把 alternating 作为一等公民实现。

3 求解器与规模

ANM 网络天然稀疏 (15 Å 截断下每节点数十条边), 瓶颈仅在特征分解。aanm-torch 的调度策略为**稀疏优先**:

- ≤ 250 个 Cα: 稠密 `eigh`(小体系更快, 且保住数值基线);
- 以上:scipy 稀疏 `eigsh`(负 shift),Hessian 由键列表稀疏组装, 内存 O(边数), 从不物化稠密矩阵;

- 无健康 scipy 时回退 GPU `lobpcg`。

多状态轨迹生成的各转换 Hessian 可堆成批量、一次 GPU 对角化 (锁步推进, 测试保证与串行逐位一致)。

表 2: 稀疏求解实测 (Mac CPU,2 线程; 每次模式求解 10 个非刚体模式)

体系规模 (残基)	每次求解	说明
2 000	2.2 s	稠密 eigh 需 14.4 s(6.4×)
5 000	12 s	稠密路线在此之上不可行
10 000	34 s	3 万自由度
20 000	≈2 min	6 万自由度, 内存 O(边数)

交叉点约在 700 个 Cα。真实数据端到端:GroEL 十四聚体 (1OEL→1AON, 公共七链组成 3668 节点的整体网络, 另七条链作为帽结构滑入) 整条轨迹 15 秒。诚实的边界:eigsh 走 CPU,GPU 加速的是多状态批量 eigh, 两者互补; 十万残基级 (病毒衣壳) 需要 RTB 块降维, 尚未实现。

4 能力扩展与缺陷修复

相对原始脚本的改进 (全部有测试支撑):

1. **整体网络 (assembly)**。同源寡聚体不再由锚链刚体复制, 全部链的节点并入同一弹性网络, 链间相对运动直接来自低频模式;
2. **交替步进**。两端交替向中间形变 (ProDy AANM_ALTERNATING 的移植), 对单向停滞体系是解药;
3. **重建三处修正**。邻居限制同链内 (原版按全局排序取邻居, 跨链借 Cα 定向)、A/B 端点源在路径中点线性混合 (消除硬切换跳变)、侧链可刚体跟随残基局部系;
4. **clash 计数修正**。原网格版只比较同一 1 Å 格内原子、系统性漏检跨格近邻, 且误计肽键; 现为精确逐对统计加残基组共价排除;
5. **蛋白/DNA/RNA 与混合体系**。每残基自动选节点 (氨基酸 Cα、核苷酸 P), 一次解析进同一网络, 截断距离按节点间距自动建议 (蛋白 ≈15 Å、RNA ≈24 Å;tRNA 1EHZ 实测通过);
6. **工程**。空帧默认报错 (原版曾静默写出 24 个空 MODEL)、重建预处理 $O(N^2) \to O(N)$、断链检测分块、全部 AANM 参数可配置、59 个单元测试 (原为零)。

5 五个经典工具的可微重写

共同设计原则: 核心运算 (成对距离、特征分解、投影) 全部为 torch 张量操作, 因此**端到端可微**——这是相对原版 Fortran/NumPy 实现的本质增量, 代价是各处刻意简化。逐项说明如下。

5.1 SAXS Debye 散射

$I(q) = \sum_{ij} f_i f_j \operatorname{sinc}(q r_{ij})$[10], 成对距离批量计算、对 q 分块。验证: 两原子解析解、30×30 naive 双循环逐点一致 (10^{-8})、autograd 梯度与有限差分一致。**取舍**: 常数电子数形状因子而非 q 依赖的 Cromer–Mann 加溶剂排除——适合相对曲线与可微拟合, 不适合绝对强度对标实验。

5.2 MinActionPath 最小作用量路径

两端 ANM 势上的 Onsager–Machlup 作用量

$$S = \sum_{k} \Big[\frac{\|x_{k+1} - x_k\|^2}{4D\,\Delta t} + \frac{\Delta t}{2}\big(V(x_k) + V(x_{k+1})\big) \Big], \tag{3}$$

中间像以 Adam 优化 (系数以 RMSD-Å 为单位,best-so-far 记账)。受 MinActionPath[6] 启发; **取舍**: 势能项按端点能量归一, 作用量绝对单位任意、只作路径间相对比较, 常数约定与原服务器不同。验证: 测试体系上优化路径作用量为线性插值的 0.844(Adam 与 LBFGS 收敛到同一极小值, 曾误判 Adam 失败, 实为动能主导区间改进空间太小)。

5.3 ANMPathway 式双向路径

双向自适应步进加**逐步软化弛豫**: 每帧相对前一帧的位移严格投影到当前网络最软模式子空间。验证: 内部步的刚性能量占比 $< 10^{-8}$(可精确检验的物理判据)。**取舍**: 原版 web 服务器 (2015 年上线的两态路径服务 ANMPathway.o) 的过渡态搜索被简化为软化判据; 汇入固定端点的收尾步豁免 (锚点不可重投影)。

5.4 ClustENM 系综采样

围绕代表构象做软模式热激发采样 (振幅以 Å 为尺度无关参数, 内部按软模式平均特征值换算温度)、clash 过滤、k-means 聚类、代表构象迭代重建网络, 遵循 ClustENM[7] 的循环结构。**取舍**: 原版的力场能量极小化弛豫替换为只激发软模式 (不引入局部应变) 加 clash 过滤。诚实边界: 无偏 ClustENM 做种子附近的平衡涨落, **不做**远距离盆地间过渡 (需 adaptive/ pathway 引导)。

5.5 NMFF 式 cryo-EM 柔性拟合

极简 MRC 读写 (仅 mode-2 float32)、可微高斯密度前向模型、实空间相关系数, ANM 模式系数由 autograd 优化, 遵循 NMFF[8] 与 DireX [9] 的模式坐标思想。**验证与边界 (重要)**: 软模式主导的目标形变可精确恢复 (CCC→1.0000、RMSD→ 10^{-5} Å); 而目标形变不在软模式子空间时 (合成体系投影仅 ≈ 0.4),CCC 仍可通过非真实形变上升——模式基表达不了的变化拟合不回去, 这是 NMFF 方法的固有边界。使用前应先验证期望形变的软模式覆盖度。

6 试点研究:ANM 软模式引导的 BioEmu 扩散采样

BioEmu[11] 是序列条件下的蛋白平衡系综扩散模型。我们测试了一个自然的组合: 去噪每步后, 把目标构象 B 相对当前结构 x 的形变向量投影到 x 的 ANM 软模式子空间, 作为引导位移注入 (即式 2 的方向、固定小步长), 使扩散过程沿物理上软的集体方向趋向 B。

协议:SDEdit 自端点 A 前向加噪至 t_0(两字段均用模型自身前向链, 预存锚定链), 高噪声段以 RePaint 式锚定把前向加噪的 A 按 0.7 比例注回、防止链熔融;$t < 0.35$ 后引导接管。对照臂为同种子同初始化、仅关闭引导。

表 3: ADK(4AKE→1AKE,214 残基,$t_0 = 0.6$,seed 0, 各 4 样本; 两参考相距 7.1 Å,Rg 为 19.5/16.4 Å)

臂	rmsd→1AKE	rmsd→4AKE	Rg (Å)
无引导、无锚定	13.5	12.3	18.6
仅引导	12.2	12.7	17.3
仅锚定	10.0	**7.7**	**19.3**
引导 + 锚定	**7.9**	9.2	17.7

两个机制独立有效且可叠加 (13.5→7.9 Å): 锚定使链真正落在 A 的正确盆地 (距 4AKE 7.7 Å、Rg 复原到晶体值), 引导再把系综推到闭态附近。**诚实的局限**:clash 基线校准显示晶体 4AKE 为 0 处、BioEmu 原生采样 1 处、我们的样本 ≈150 处 (<4 ÅCα)——盆地级控制达成, 残基级几何仍未干净, 根因是锚定期取向约定与模型内部约定存在出入。达到物理级帧的正规路径是 BioEmu ≥1.3 的 steering 框架 (自定义势 + 粒子重采样无偏修正; 我们已按 1.4.1 源码接口写好软模式 CV 与配置, 待 Linux/CUDA 机器) 或逐帧能量弛豫。

7 可复现性

仓库 (aanm-torch, 含 59 个单元测试: 几何 (Kabsch/旋转插照)、Hessian 手算值与对称性、三求解器互检、clash 语义、重建连续性、批量-串行一致、蛋白与核酸端到端轨迹, 以及 ProDy 对照 (子进程运行设计者 venv 的 ProDy 2.4.1, 逐步 RMSD 差 $\leq 10^{-9}$)。运行环境仅需 `torch>=2.0` 与 `numpy`, 稀疏求解加 `scipy`。基准脚本 `experiments/04_bench_sparse.py` 复现表 2。

参考文献

[1] Atilgan AR, Durell SR, Jernigan RL, Demirel MC, Keskin O, Bahar I. Anisotropy of fluctuation dynamics of proteins with an elastic-network model. *Biophysical Journal*, 2001, 80: 505–515.

[2] Bakan A, Meireles LM, Bahar I. ProDy: protein dynamics inferred from theory and experiments. *Bioinformatics*, 2011, 27(11): 1575–1577.

[3] Bakan A, Dutta A, Maiorov V, Bahar I. Evol and ProDy for bridging protein sequence structure and dynamics. *Bioinformatics*, 2014, 30(18): 2681–2683.

[4] Yang Z, Májek P, Bahar I. Allosteric transitions of supramolecular systems explored by network models: application to chaperonin GroEL. *Biophysical Journal*, 2009, 96(11): 4438–4446.

[5] Kabsch W. A solution for the best rotation to relate two sets of vectors. *Acta Crystallographica A*, 1976, 32: 922–923.

[6] Franklin J, Koehl P, Doniach S, Delarue M. MinActionPath: maximum probability path for kinetic modeling of biomolecular structural changes. *Journal of Chemical Physics*, 2007, 127: 175101.

[7] Kurukoğlu Z, Doruker M. ClustENM: ENM-based sampling of conformational space coupled with clustering. *Proteins*, 2016, 84: 596–607.

[8] Tama F, Miyashita O, Brooks CL III. Flexible multi-scale fitting of atomic structures into low-resolution electron density maps with elastic network normal mode analysis. *Journal of Molecular Biology*, 2004, 337(4): 985–999.

[9] Schröder GF, Brunger AT, Levitt M. Combining efficient conformational sampling with a deformable elastic network to facilitate the simultaneous fitting of low-resolution X-ray and cryo-EM data. *Structure*, 2007, 15(8): 915–925.

[10] Debye P. Zerstreuung von Röntgenstrahlen. *Annalen der Physik*, 1915, 351: 809–823.

[11] Lewis M, Wu T, et al. Learning to emulate protein equilibrium ensemble dynamics with diffusion models. *Science Advances*, 2025. doi:10.1126/science.adv9817 (preprint: bioRxiv 2024.12.05.626885).